Databáze mluvených projevů v češtině jako cizím jazyce (státní občanství v ČR)

Databáze mluvených projevů v češtině jako cizím jazyce (státní občanství v ČR) je jazykový korpus mluvených projevů nerodilých mluvčích češtiny zaměřený na jazykovou úroveň B1 (podle SERR), požadovanou pro udělení státního občanství v České republice. Obsahuje nahrávky zaznamenávající ústní část Certifikované zkoušky z češtiny pro cizince[1]. Nahrávky zahrnují dialogy mezi zkoušejícím (rodilým mluvčím) a kandidátem zkoušky (nerodilým mluvčím). Kromě nahrávek korpus obsahuje také jejich přepisy, které jsou opatřeny bohatou lingvistickou anotací.

Korpus je zveřejněn jako specializovaná veřejná databáze s cílem poskytnout strukturovaný a snadno přístupný zdroj autentických mluvených dat pro lingvisty, pedagogy, studenty, vědeckou komunitu a širokou veřejnost.

Jazykový korpus byl vytvořen v Ústavu formální a aplikované lingvistiky Matematicko-fyzikální fakulty Univerzity Karlovy[2] za účelem podpory výuky, výzkumu a hodnocení jazykové kompetence nerodilých mluvčích češtiny v rámci projektu *Automatické hodnocení mluveného projevu v češtině*[3]. Audionahrávky poskytl Ústav jazykové a odborné přípravy Univerzity Karlovy[4].

Statistiky

Databáze obsahuje 65 nahrávek. Zachycuje 36 zkoušek a stejný počet nerodilých mluvčích. Celková délka všech nahrávek je 4h 51min 48s. Tabulka níže ukazuje statistiky přepisů.

	Počet
Soubory	65
Repliky	3 348
Tokeny	29 572

Dokumentace

- Uživatelská příručka[5]
- Technická dokumentace[6]

[1] http://ujop.cuni.cz/cce
[2] https://ufal.mff.cuni.cz/
[3] https://ufal.mff.cuni.cz/automated-speech-scoring-czech
[4] https://ujop.cuni.cz/
[5] USER_MANUAL-cs.md
[6] TECH_DOC-cs.md

Licence

Korpus je zveřejněn pod licencí CC BY-NC-SA 4.0.

Financování

Vznik databáze byl financován z prostředků Programu na podporu aplikovaného výzkumu v oblasti národní a kulturní identity na léta 2023 až 2030 (NAKI III) Ministerstva kultury ČR v rámci projektu *Automatické hodnocení mluveného projevu v češtině* (DH23P03OVV037).

Poděkování

Autoři databáze srdečně děkují PhDr. Pavlovi Pečenému, Ph.D., z Ústavu jazykové a odborné přípravy Univerzity Karlovy za poskytnutí audiodat.

Jak citovat

Rysová Kateřina, Novák Michal, Rysová Magdaléna, Polák Peter, Bojar Ondřej: *Databáze mluvených projevů v češtině jako cizím jazyce (státní občanství v ČR)*. Ústav formální a aplikované lingvistiky MFF UK, Praha 2026. Dostupná z WWW http://hdl.handle.net/11346/H4WT.